

Seminário de Algoritmos Bioinspirados - 2026

Alocação de Máquinas Virtuais na Nuvem

Otimização bioobjetivo com Colônia de Formigas (VMPACS)

Energia x Desperdício de recursos

Lucas Rivetti e Ian Nunes



1 O problema: alocação de VMs

O que é?


- Decidir em qual servidor físico cada máquina virtual (VM) será executada.
- Consolidar VMs em poucos servidores e desligar os ociosos economiza energia.
- Mas servidores mal balanceados (CPU cheia, memória vazia) desperdiçam recursos.
- É uma variante do empacotamento vetorial: NP-difícil (m^n alocações possíveis).

Consolidação

Antes: 7 servidores subutilizados



Depois: 3 servidores bem ocupados



2 Dois objetivos em conflito

E

Consumo de energia

- Potência cresce linear com o uso de CPU.
- Servidores ociosos são desligados.
- Minimizar energia ~ usar menos servidores.

W

Desperdício de recursos

- Penaliza desbalanceamento entre CPU e memória.
- Servidores muito cheios ou vazios desperdiçam.
- Minimizar = empacotar de forma equilibrada.

Conflito: reduzir servidores pode desbalancear -> buscamos o conjunto de melhores compromissos (a **fronteira de Pareto**).

3 Formulação matemática

Objetivos (minimizar simultaneamente):

$$f_1 = \sum_j y_j [(P^{busy} - P^{idle}) \sum_i x_{ij} R_i^P + P^{idle}]$$

energia

$$f_2 = \sum_j y_j \frac{|L_j^P - L_j^M| + \varepsilon}{U_j^P + U_j^M}$$

desperdício

Sujeito a:

$$\sum_j x_{ij} = 1; \quad \sum_i R_i^P x_{ij} \leq T_j^P y_j; \quad \sum_i R_i^M x_{ij} \leq T_j^M y_j$$

Variáveis binárias: x_{ij} = VM i no servidor j ; y_j = servidor j em uso. Limites $T = 90\%$ | $P_{idle}=162W$, $P_{busy}=215W$.

4 VMPACS: a metáfora das formigas

Formigas depositam feromônio nos bons caminhos; caminhos bons atraem mais formigas. Aqui, cada formiga constrói uma alocação e reforça os bons movimentos (VM -> servidor).

τ

Feromônio (tau)

Memória do que funcionou:
movimentos usados por boas
soluções ganham mais feromônio.

η

Heurística (eta)

Conhecimento do problema:
prioriza movimentos que poupam
energia e equilibram recursos.

P

Arquivo de Pareto

Guarda as soluções não-
dominadas; só elas reforçam o
feromônio (atualização global).

5 VMPACS: como uma formiga constrói

1

Abre um servidor

Começa um novo servidor (host) para receber VMs.

2

Escolhe a próxima VM

Regra pseudoaleatória: combina feromônio + heurística ($q_0=0.8$ intensifica, senão explora).

3

Atualização local

Após cada movimento, evapora um pouco do feromônio para diversificar.

4

Atualização global

No fim da iteração, as soluções de Pareto reforçam seus movimentos.

Regra de escolha do movimento

intensificar ($q \leq q_0$):

escolhe o movimento com maior

$$\alpha * \tau + (1 - \alpha) * \eta$$

explorar ($q > q_0$):

sorteia proporcional a esse valor.

Repete até alocar todas as VMs; cada formiga gera uma solução completa.

6 Comparação: NSGA-II

Algoritmo genético multiobjetivo mais usado (Deb et al., 2002) - assim como o artigo compara o VMPACS com um algoritmo genético.

1 Ordenação não-dominada

Classifica a população em frentes de Pareto sucessivas (frente 0 = melhores).

2 Distância de multidão

Mede o isolamento de cada solução para manter a fronteira bem espalhada (diversidade).

Codificação: cada indivíduo é uma permutação das VMs, decodificada por first-fit (sempre válida).

Operadores: Order Crossover (OX) + mutação por troca; seleção por torneio e elitismo.

7 Metodologia experimental

I

Instâncias

n = 100 VMs e 100 servidores; 5 níveis de correlação CPU/memória (P de 0 a 1); limites de 90%.

P

Parâmetros

VMPACS: 10 formigas x 100 iterações. NSGA-II: pop. 50 x 20 gerações. ~1000 avaliações cada (justo).

M

Métricas (4)

Hipervolume e IGD (convergência), ONVG (cardinalidade), Spacing (uniformidade).



R

Execuções

10 repetições independentes por configuração; média +/- desvio-padrão.

8



Resultados: energia e desperdício



Leitura: o NSGA-II atinge menor energia em 4 de 5 cenários e menor desperdício em 4 de 5 (exceção em $P=0.5$).




9

Resultados: métricas multiobjetivo



Convergência

- HV maior = melhor
- IGD menor = melhor
- trade-off real e raso



10 Discussão

Convergência

NSGA-II converge para menor energia e desperdício (maior HV, menor IGD) na maioria dos casos.

Diversidade

VMPACS encontra mais soluções não-dominadas (ONVG) em correlações negativas.

Fronteira compacta

Empacotar bem reduz energia E desperdício juntos: objetivos quase alinhados.

Correlação importa

$P=0.75$ (CPU e mem. altas juntas) gera o maior desperdício; balancear fica difícil.

11 Conclusões

- 1 Implementamos o VMPACS (colônia de formigas) e o NSGA-II no problema bioobjetivo de alocação de VMs.
- 2 Com orçamentos iguais, o NSGA-II convergiu melhor; o VMPACS ofereceu fronteiras um pouco mais diversas.
- 3 Para estas instâncias os objetivos são quase alinhados, gerando fronteiras de Pareto compactas - um resultado instrutivo.

Trabalhos futuros: instâncias maiores ($n=2000$), servidores heterogêneos e versão memética do VMPACS (com busca local).

12 Referências

- [1] Gao, Guan, Qi, Hou, Liu (2013). A multi-objective ant colony system algorithm for virtual machine placement in cloud computing. J. of Computer and System Sciences, 79(8), 1230-1242.
- [2] Deb, Pratap, Agarwal, Meyarivan (2002). A fast and elitist multiobjective genetic algorithm: NSGA-II. IEEE Trans. on Evolutionary Computation, 6(2), 182-197.
- [3] Dorigo, Gambardella (1997). Ant colony system: a cooperative learning approach to the TSP. IEEE Trans. on Evolutionary Computation, 1(1), 53-66.
- [4] Zitzler, Thiele (1999). Multiobjective evolutionary algorithms: a comparative case study and the strength Pareto approach. IEEE Trans. on Evol. Computation, 3(4), 257-271.
- [5] Van Veldhuizen (1999). Multiobjective Evolutionary Algorithms: Classifications, Analyses, and New Innovations. PhD thesis, Air Force Institute of Technology.

Obrigado! Perguntas?